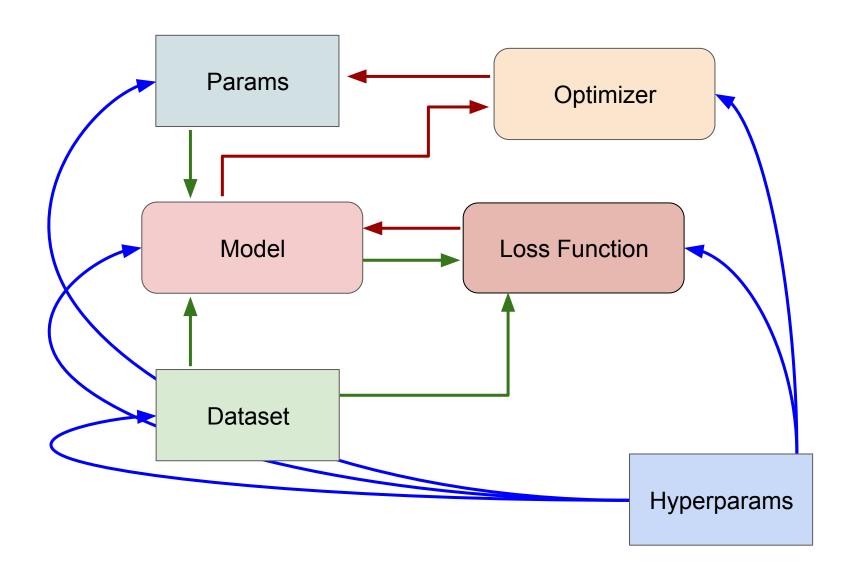
Unidad 2: Redes Neuronales Artificiales

Curso: Redes Neuronales Profundas

Visión Modular



Funciones de costo

Teorema de Bayes


$$p(h|D) = \frac{p(D|h)p(h)}{p(D)}$$

Probabilidad de haber visto los datos, suponiendo la hipótesis

Likelihood. Si suponemos i.i.d., es un producto.

$$\sum_{d_i \in D} \log(p(d_i|h)) \qquad \text{Log likelihood}$$

Aprendizaje supervisado



probabilidad de los inputs

Clasificación



$$\sum_{(x_i,y_i)\in D}\log(p(y_i|x_i,h)) \qquad \text{Representación One hot:} \quad p_{ij}\in\{0,1\}$$

$$\text{i-ésimo} \quad \text{j-ésima} \quad \text{dato} \quad \text{clase}$$

El modelo es una función f tal que dada x_i devuelve la probabilidad q_{ij} para cada una de las clases

$$-\sum_{i=1}^{N} \sum_{j=1}^{C} p_{ij} \log(q_{ij})$$
 Cross-entropy

theano.tensor.nnet.categorical_crossentropy(coding_dist, true_dist)

Return the cross-entropy between an approximating distribution and a true distribution. The cross entropy between two probability distributions measures the average number of bits needed to identify an event from a set of possibilities, if a coding scheme is used based on a given probability distribution q, rather than the "true" distribution p. Mathematically, this function computes $H_{1}(n,q) = -\sum_{n=1}^{C} n_{n} \log(q_{n})$

 $H_i(p,q) = -\sum_{j=1}^{C} p_{ij} \log(q_{ij})$

where p=true_dist and q=coding_dist.

Parameters:

- coding_dist symbolic 2D Tensor (or compatible). Each row represents a distribution.
- true_dist symbolic 2D Tensor OR symbolic vector of ints. In the case of an integer vector argument, each element represents the position of the '1' in a 1-of-N encoding (aka "one-hot" encoding)

Return type: tensor of rank one-less-than coding_dist

theano.tensor.nnet.categorical_crossentropy(coding_dist, true_dist)

Note:

An application of the scenario where *true_dist* has a 1-of-N representation is in classification with softmax outputs. If coding_dist is the output of the softmax and true_dist is a vector of correct labels, then the function will compute

which corresponds to computing the neg-log-probability of the correct class (which is typically the training criterion in classification settings).

```
y = T.nnet.softmax(T.dot(W, x) + b)
cost = T.nnet.categorical_crossentropy(y, o).mean()
# o is either the above-mentioned 1-of-N vector or 2D tensor
```

Clasificación binaria

$$-\sum_{i=1}^{N} \sum_{j=1}^{C=2} p_{ij} \log(q_{ij})$$
 Cross-entropy

$$-\sum_{i=1}^{N} \left[p_{i1} \log(q_{i1}) + p_{i2} \log(q_{i2}) \right] \\ -\sum_{i=1}^{N} \left[p_{i} \log(q_{i}) + (1-p_{i}) \log(1-q_{i}) \right]$$

```
p_1 = 1 / (1 + T.exp(-T.dot(x, w) - b)) # Prob. that target = 1

prediction = p_1 > 0.5

p
```

Regresión

$$y = f(x) + \epsilon - Normal$$

$$p(y|x) = \mathcal{N}(y|f(x), \sigma)$$

$$p(y|x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{1}{2}\left(\frac{y-f(x)}{\sigma}\right)^2}$$

Regresión

 $\log p(y|x)$

$$-\log(\sigma\sqrt{2\pi}) - \frac{1}{\sigma^2} \left[\frac{1}{2} (y - f(x))^2 \right]$$

Si sumamos para todos los $(x_i, y_i) \in D$,

$$-N\log(\sigma\sqrt{2\pi}) - \frac{1}{\sigma^2} \sum_{(x_i, y_i) \in D} \left[\frac{1}{2} (y_i - f(x_i))^2 \right]$$

Funciones de costo en Theano

```
1 import theano
2 import theano.tensor as T
3
  def CategoricalCrossEntropy(y_true, y_pred):
5
       return T.nnet.categorical_crossentropy(y_pred, y_true).mean()
 6
  def BinaryCrossEntropy(y true, y pred):
8
       return T.nnet.binary crossentropy(y pred, y true).mean()
9
10 def MeanSquaredError(y true, y pred):
11
       return T.sqr(y pred - y true).mean()
12
13 def MeanAbsoluteError(y true, y pred):
14
       return T.abs (y pred - y true).mean()
15
```

Descenso por gradiente

Backpropagation

$$L = L(y, \hat{y}) \qquad \hat{y} = F(x)$$


$$V$$

$$W_3 \qquad W_2 \qquad W_1$$


$$F(x) = f_3(W_3, f_2(W_2, f_1(W_1, x)))$$

$$F(x) = f_3(W_3) \circ f_2(W_2) \circ f_1(W_1)(x)$$

Backpropagation



Backprop sobre una neurona




$$z_i = W_i \cdot x + b_i$$

 $h_i = \text{relu}(z_i)$

$$\frac{\partial L}{\partial W_i} = \frac{\delta_{bp}}{\partial z_i} \frac{\partial h_i}{\partial z_i} \frac{\partial z_i}{\partial W_i}$$

$$\frac{\partial L}{\partial W_i} = \frac{\delta_{bp}}{\delta_{bp}} \operatorname{step}(z_i) x$$



SGD

```
class SGD:
    def __init__(self, Ir=0.01):
        self.Ir = Ir

def __call__(self, params, cost):
        updates = []
        grads = T.grad(cost, params)
        for p,g in zip(params,grads):
            updated_p = p - self.Ir * g
            updates.append((p, updated_p))
        return updates
```

SGD + Momentum

```
class Momentum:
  def init (self, lr=0.01, momentum=0.9):
  def call (self, params, cost):
    updates = []
    grads = T.grad(cost, params)
    for p,g in zip(params,grads):
       m = theano.shared(p.get_value() * 0.)
       v = (self.momentum * m) - (self.lr * g)
       updates.append((m, v))
       updated_p = p + v
       updates.append((p, updated_p))
    return updates
```

Nesterov

```
class NAG.
  def init (self, lr=0.01, momentum=0.9):
  def call (self, params, cost):
    updates = []
    grads = T.grad(cost, params)
    for p, g in zip(params, grads):
       m = theano.shared(p.get value() * 0.)
       v = (self.momentum * m) - (self.lr * g)
       updated_p = p + self.momentum * v - self.lr * g
       updates.append((m,v))
       updates.append((p, updated p))
    return updates
```

Momentum común: primero computa el gradiente, luego hace un salto grande en la dirección del gradiente acumulado.

Mejor: Primero hacer el salto grande y luego medir el gradiente.

Inconvenientes de SGD tradicional


- ¿Cómo elegimos el learning rate?
- El learning rate es el mismo para todos los parámetros.
 Para features que se dan raramente, puede ser que convenga utilizar saltos más grandes.
- Trampas: mínimos locales subóptimos (raros) o puntos de ensilladura donde el gradiente tiende a 0.

AdaGrad

Idea: hacer updates grandes para parámetros infrecuentes y updates chicos para parámetros frecuentes. Sirve para sparse data.

El learning rate correspondiente a un parámetro p en el tiempo T se escala con

$$\sqrt{\sum_{t=1}^{T} grad_t(p)^2}$$



AdaGrad

```
class Adagrad:
  def init (self, lr=0.01, epsilon=1e-6):
  def __call__(self, params, cost):
                                                       2
     updates = []
                                                       0
     grads = T.grad(cost, params)
                                                       -2
                                                       -4
     for p,g in zip(params,grads):
                                                         1.0
       acc = theano.shared(p.get_value() * 0.)
                                                           0.5
                                                              0.0
       acc t = acc + g ** 2
                                                                 -0.5
                                                                                     0.0
                                                                   -1.0
       updates.append((acc, acc_t))
                                                                                 -0.5
                                                                      -1.5
       p_t = p - (self.lr / T.sqrt(acc_t + self.epsilon)) * g
       updates.append((p, p_t))
     return updates
```

SGD

NAG

Adagrad Adadelta Rmsprop

Momentum

1.0

0.5

RMSprop

```
class RMSprop:
  def init (self, lr=0.001, rho=0.9, epsilon=1e-6):
  def call (self, params, cost):
    updates = []
    grads = T.grad(cost, params)
    for p,g in zip(params,grads):
       acc = theano.shared(p.get_value() * 0.)
       acc_t = self.rho * acc + (1 - self.rho) * g ** 2
       updates.append((acc, acc t))
       p_t = p - (self.lr / T.sqrt(acc_t + self.epsilon)) * g
       updates.append((p, p t))
    return updates
```

Sumar sobre todo el pasado trae problemas.

Solución: usar un decay exponencial

Adam

```
class Adam:
  def init (self, lr=0.001, b1=0.9, b2=0.999,
               e=1e-8. I=1-1e-8):
  def call (self, params, cost):
    updates = []
    grads = T.grad(cost, params)
    t = theano.shared(floatX(1.))
    b1 t = self.b1*self.l**(t-1)
    for p, g in zip(params, grads):
       m = theano.shared(p.get value() * 0.)
       v = theano.shared(p.get_value() * 0.)
       m t = b1 t*m + (1 - b1 t)*g
       v t = self.b2*v + (1 - self.b2)*g**2
       m c = m t / (1-self.b1**t)
```

Combinación de RMSprop con Momentum

¿Cuál usar?

- No hay una diferencia importante entre los diferentes métodos con learning rate adaptativo. Kingma muestra una leve mejora de Adam frente a RMSprop.
- Con una buena inicialización, SGD puede llegar a mínimos similares. Pero con más tiempo.
- Para datos o representaciones internas sparse, los métodos adaptativos muestran su ventaja. ¿Recuerdan las ReLU?

